



中期进展报告（2026-09-07）

胡琦

一.设计思想

用户使用体验友好型导向优先,以实现后台工作全面自动化为主,主以传统计算机工具也即tools来取代本地模型的大部分工作.(本人负责部分)

二.组织分工和当前结果

我本人负责agent相关的模型的部署和tools程序项目搭建.

高杉和祝一顺主要负责剧本,分镜,视频创作等,王恩照负责辅助执行的任务.

我们在DGX Spark 近乎搭起了一条从“一句创意”到“一条带台词、字幕、配乐的成片”的**全自动视频生产线**(但是仍然是有许多需要修缮的bug等部分)中间几乎不需要云端服务,日常只需要对qwen模型的交互界面输入话语就能等待拿到成品。

三、做了什么（我本人负责）

1. 用自然语言指挥它（Agent 能力）。 与助手对话时，如果是单纯的任务意见,助手会自己完成：把创意扩写成符合模型口味的英文提示词、否则会严格执行输入内容的要求。

（不能碰服务器配置、不能乱取消别人的任务），涉及跨会话素材时会申请一次性授权。

2. 配音与声音管道。

- 音色是“克隆式”的：给一个参考音频，模型就模仿那个音频说话——所以我把音色都换成了官方/真人素材；
- 中文声已切换为**更自然的本地语音大模型（CosyVoice2）**，合成接近真人语气。
- 英文播报也有了真人声音色（新闻播报式台词直接可用）；
- 台词会自动生成字幕、替换原音轨，配音质量用**语音识别回环自动验收**（识别结果与原文比对，达标才算过

3. 音效与配乐。 模型原生声音控制困难（脚步声乱配、音乐突兀）——我们改为可采用后期独立合成音轨：

跑步声、电视开机音、电子乐转氛围垫音都能精确卡在秒级时间点，与配音、配乐三路混音后交付。

4. 质量后端。 自动 2 倍清晰化（降噪+锐化）、4 倍超分、故障断点续传、每个任务留完整

档案

（参数、用图、日志、产物路径都可追溯）。

四、现状与风险

- **资源**：单机共享 GPU，生成队列忙时需排队（这是为什么有些大活儿约好“空闲窗口”再做）；
- **渠道**：有些外部模型下载通道不通，已全部切换到可用镜像；
- **已知短板**：口语化情绪（惊讶、哭泣）暂不保证；原生 1080p 在探测中（当前为高清档+超分），而且生成极其花费时间,正在探索考虑优化方案；
- **历史教训**：早期曾用廉价在线音色冒充本地大模型（听感“电子音”），已从根上换掉并建立了客观验收。
- **待解决问题**：agent 模型经常故障,需要合理设置上下文等,注入系统提示词量大,对本地小模型不友好,没有使用沙箱限制模型agent工作范围,存在风险

五、下一步计划

1. 用新自然音色重出待定稿的镜头，并合并成“生成+配音+验收”一张工作流（一键出成品）；
2. 原生 1080p 探测与口型驱动.
3. 把“一句话出片”打磨得更稳：更长的多镜头成片、更丰富的音色库。